김민규

학력 / 교육

2017.03 - 2023.09	부산대학교 산업공학 학사 / 통계학 부전공
2023.09 - 2024.04	모두의 연구소 부트캠프 AI 엔지니어 양성과정

직무경험

2024.04 - 현재 (1년 11개월)	비쥬웍스 | 데이터과학자

[비쥬웍스] 예측지표 기반 렌즈 삽입술 보조 서비스 개발

- 개요 : 수술경과예측 등을 통해 수술과정에서의 의사결정 프로세스 개선
- 일정 : 2025.06 ~ 2026.12 (6개월)

- 현장 인터뷰를 통해 예측 성능와 신뢰도가 비례하지 않는 문제를 정의하고, 이를 해결하기 위해 신뢰도 평가지표를 설계해 모델의 신뢰도를 평가 및 고도화
- 현장 인터뷰를 통해 의사결정에 도움이 되기 위한 조건을 정의하고, 단순한 조건부 평균 예측이 아닌 조건부 분위수 추정에 기반한 분포 추정 및 위험도 정량화를 통한 의사결정 지원
- 파편화된 정형, 비정형 데이터를 통합하는 데이터 파이프라인을 구축하고, 피처 스토어에 기반해 데이터 일관성을 보장하는 구조를 설계해 학습-서빙 간 feature 불일치 및 재현성 문제를 해결
- 모델을 실험 수준에서 벗어나 운영 가능한 서비스로 확장하기 위해 서빙, 버전 관리, 성능 및 분포 모니터링 체계를 포함한 End-to-End ML 시스템을 구축하고, silent failure를 조기에 감지해 운영 안정성을 확보

[비쥬웍스] 고객상담용 챗봇 개발

- 개요 : RAG 기반 pipeline을 통해 상담업무 효율성 개선
- 일정 : 2024.12 ~ 2025.5 (6개월)

- 현장 인터뷰를 통해 모호한 요구사항을 구체적인 기술적 요구사항으로 정의하고, 이를 만족시키기 위해 분류 모델을 적용한 RAG 아키텍처를 설계해 요구사항 만족
- 벡터 기반 유사도 검색의 한계를 보완하기 위해 질의 재작성, 키워드 추출 기반 하이브리드 검색, 복합 질의 분해 등을 통해 검색 성능 향상
- 맥락이 충분히 반영되지 않는 문제를 개선하기 위해 QnA 기반 few-shot 형태의 프롬프트 고도화를 통해 답변 일관성 및 정확도 향상

- 개요 : 다국어로 서비스 확장 및 문서 관리 용이성을 위해 Agentic-RAG로 구조 변경
- 일정 : 2026.12 ~ 2026.02 (2개월)

- 다국어 서비스 확장과 문서 관리 복잡도 증가에 따라 기존 semantic search 기반 RAG 구조를 LLM이 검색 툴을 직접 호출하는 Agentic-RAG 아키텍처로 전환하여 검색 성능 및 관리 복잡도 개선

[비쥬웍스] OCR 서비스 개발

- 개요 : 파편화된 비정형 검사 이미지 데이터를 OCR pipeline을 통해 정규화해 데이터 접근성과 활용성을개선하고, AI 서비스가 실제 운영 환경에 적용될 수 있는 기반을 마련
- 일정 : 2024.08 ~ 2024.12 (4개월)

- 검사 이미지의 레이아웃 특성을 분석해 detection-recognition 분리 구조로 설계하고 detection을 rule-based로 최적화, recognition에 특화 모델을 적용함으로써 99% 인식 정확도와 1초 미만 처리 속도를 동시에 달성
- 객체지향적 모듈 설계를 적용하고 단위 테스트 체계를 도입해 유지보수성을 향상시키고 런타임 오류를 감소

예측지표 기반 렌즈 삽입술 보조 서비스 개발

[End-to-End ML systm 구축]

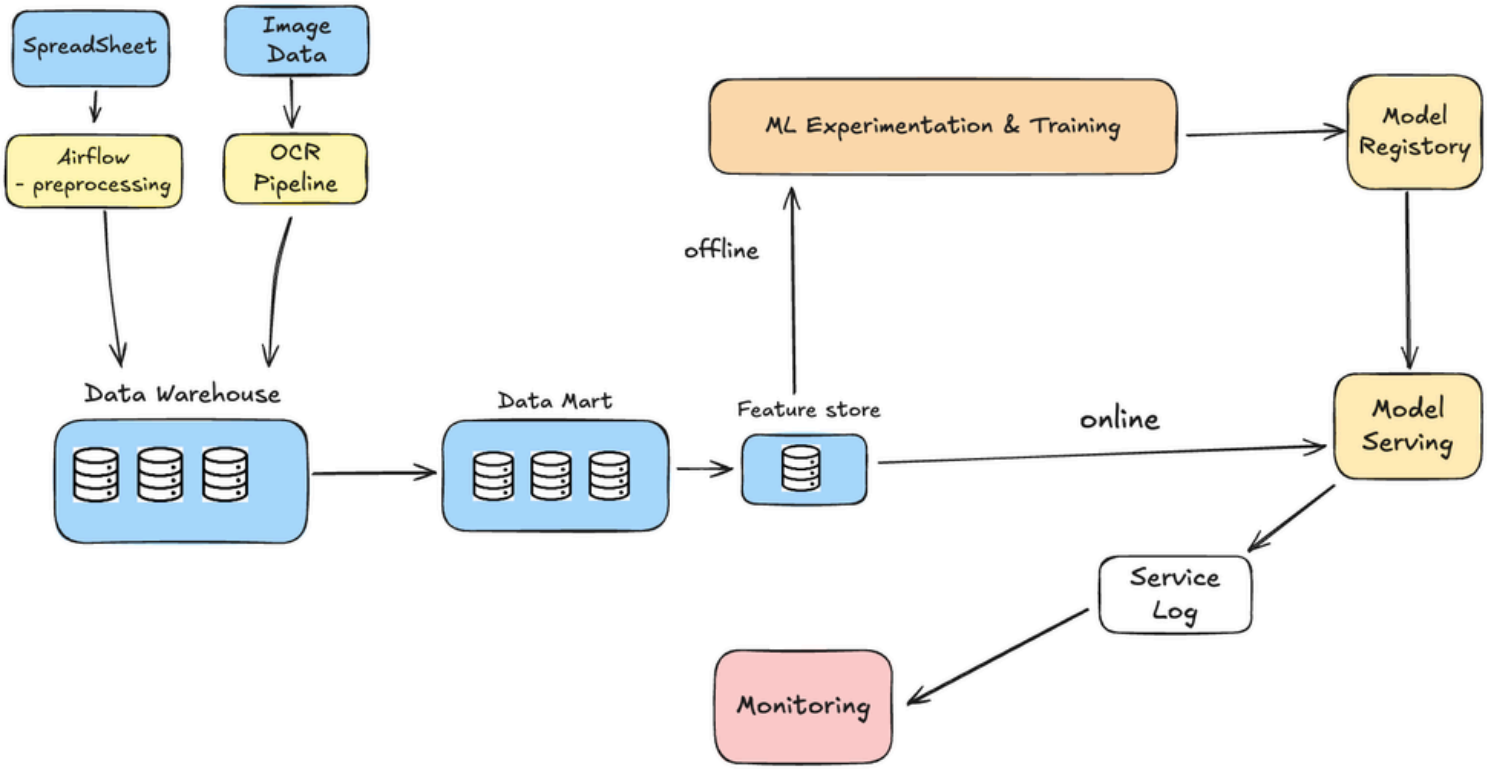

〈 문제 〉

- 파편화된 데이터와 체계화되지 않은 데이터 관리로 인해 데이터 일관성과 재현성 확보의 어려움
- 학습 환경과 추론 환경 간 데이터 불일치로 모델 성능 저하 리스크가 존재

〈 해결 〉

- 표준화된 ETL 파이프라인과 DW-DM 구조를 설계해 데이터 거버넌스를 정립하고, 분석 및 모델링에 최적화된 데이터 레이어를 구축.
- Feature Store를 도입해 학습, 추론 환경에서 동일한 피처 생성 로직을 공유하도록 설계함으로써 학습-서빙 간 데이터 불일치를 차단하고 ML 운영 안정성을 확보

〈 문제 〉

- 운영 환경에서 데이터 분포 변화나 모델 성능 저하를 실시간으로 감지할 체계가 부재하여, 오류 없이 잘못된 예측을 수행하는 Silent Failure 발생 리스크 존재

〈 해결 〉

- 입력 피처 분포, 예측값 분포 및 핵심 성능 지표를 주기적으로 모니터링하는 파이프라인을 구축해 Data Drift 및 추론 단계 성능 저하를 조기 감지하고, Silent Failure를 사전에 예방할 수 있는 운영 체계 수립

[신뢰도를 고려한 평가지표 설계]

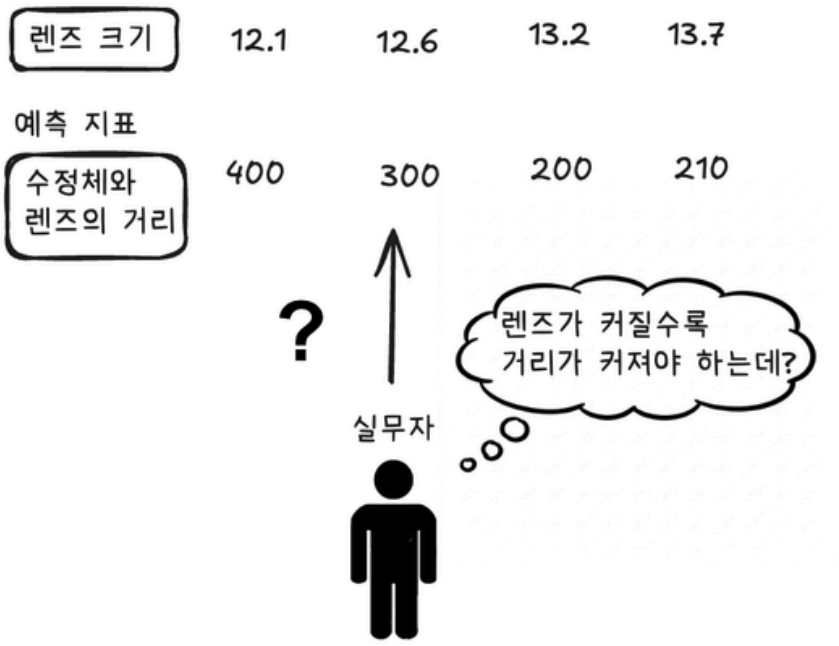

〈 문제 〉

- 모델의 추론성능 (MSE, R^2) 과 별개로 실무자가 공유하고 있는 직관과 맞지 않아 모델의 신뢰도가 떨어지는 문제

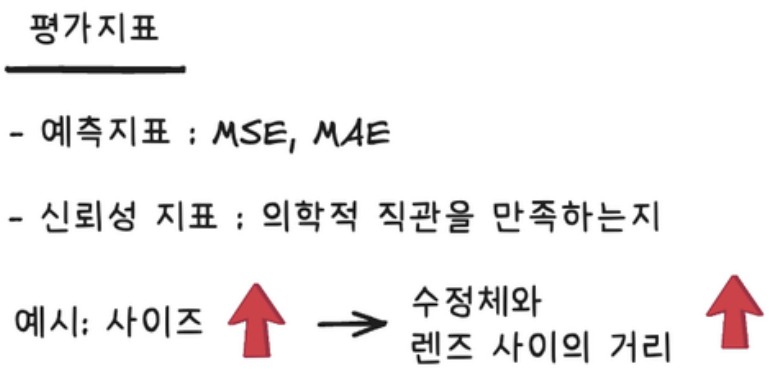

〈 해결 〉

- 인터뷰를 통해 현장에서 공유하는 관계를 정의하고, 이를 만족하는지를 평가지표로 설계
- 예시 : 렌즈와 수정체 사이의 거리의 관계처럼 단조성을 만족하는 여부를 평가지표 설계 (렌즈와 수정체 사이의 단조성이 만족하는지 계산)
- 이를 통해 모델의 신뢰성을 평가하고, 신뢰할 수 있는 방향으로 고도화

[의사결정을 돕기 위한 모델 및 서비스 기획]

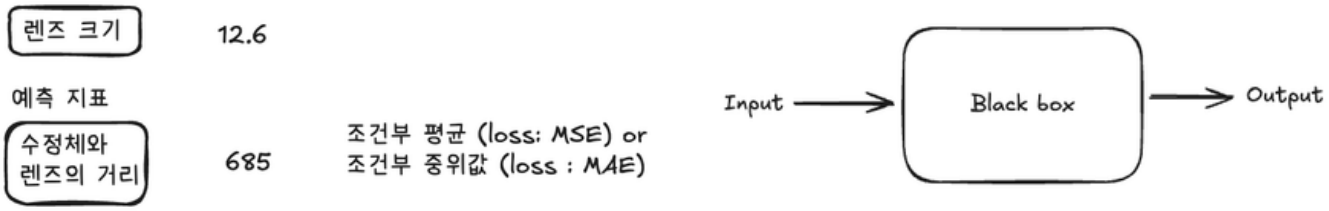

〈 문제 〉

- 현장의 실무자와의 인터뷰를 통해 의사결정에 도움이 되기 위한 조건 정의
- 단일 예측값은 의사결정에 도움이 되지 않음
- 수술의 평균적인 결과 외에 최악의 경우에 대한 예측값과 이에 대한 위험도를 정량화 필요

- 모델에 대한 설명력이 중요
  (인터뷰를 통해 설명되지 않는 모델은 신뢰를 가지기 어려움을 이해)

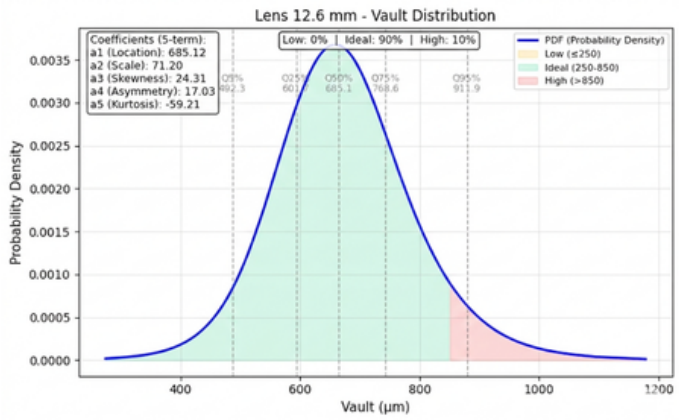

- 조건부 분위수 추정 (loss : pinball loss)
- 분포 추정 (metalog) -> risk 확률 추정

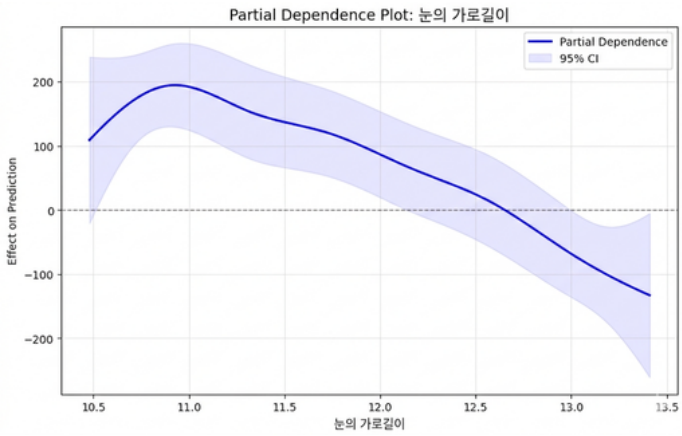

〈 해결 〉

- 단순한 예측값 (조건부 평균)이 아닌 pinball loss를 통해 조건부 분위수를 추정
- 추정한 분위수를 기반으로 Metalog를 통한 분포 추정
- 이를 통해 특정 범위에 대한 확률을 제공해 위험도를 정량화해서 제공

- 블랙박스 모델이 아닌 독립변수가 종속변수에 미치는 영향도를 시각화해 제공
- 예측결과 뿐만 아니라 영향도를 통해 의학적인 해석에 도움 제공

→ 이는 사용자가 서비스에 가지는 신뢰도에도 긍정적인 영향을 줌

- 예측 지표 외에도 통계분석 결과를 통해 의사결정에 도움이 되는 분석 결과 제공

고객상담용 챗봇

[인터뷰를 통해 정의한 요구사항을 만족하기 위한 RAG pipeline 구축]

〈 문제 〉

- 현장 인터뷰를 통해 모호한 요구사항을 기술적인 요구사항으로 정의
- 상담사 연결을 요청하거나 예약과 관련된 질문 등은 답변 생성이 아닌 고정된 형태의 답변을 제공해야 함
- 기본적인 RAG 구조는 비효율적

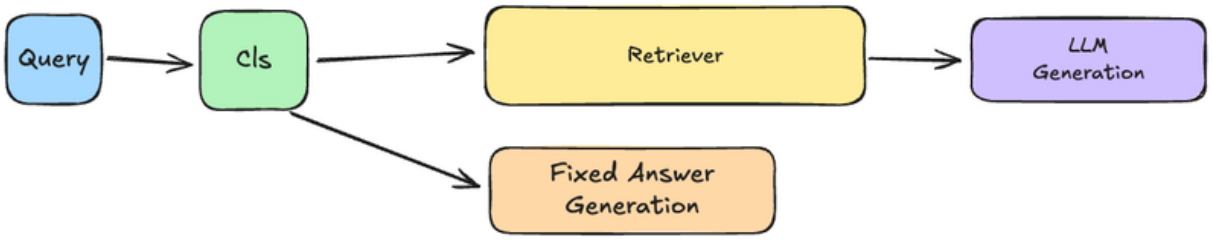

〈 해결 〉

- 파이프라인 맨 앞에 의도 분류 모듈을 붙여 검색-생성이 필요한 경우와 고정된 답변과 연결 버튼 등을 생성이 필요한 경우를 구분
- Few-shot prompting을 활용해 LLM 기반 질의 분류 모델을 설계 및 구현
- 이를 통해 요구사항 만족 및 불필요한 LLM 답변 생성을 줄여 운영 효율성 및 안정성 증가

[질의 재정의, 질문 분해 및 키워드 추출 등을 통한 검색 성능 향상]

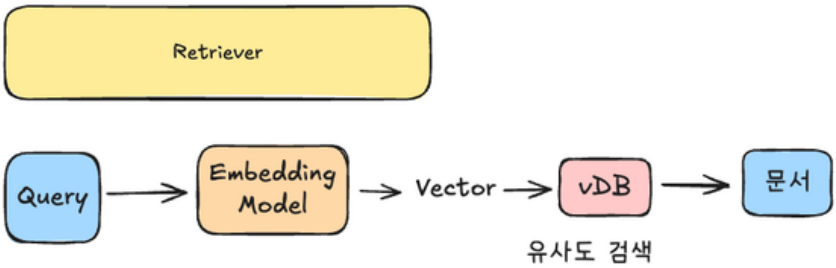

〈 문제 〉

- 단순한 벡터 기반 유사도 검색은 다음과 같은 문제들이 존재
- 맥락을 고려하지 못하는 문제
  - “라섹 가격 알려줘?”를 묻고 “라식은?”이라고 물었을 때 “라식 가격"에 대한 검색을 할 수 없었음
- 복합 질의를 처리하지 못하는 문제
  - “라식과 라섹의 가격 알려줘"라는 질문에 라식의 가격과 라섹의 가격에 대한 문서를 가져오지 못하는 문제
- 도메인 특유의 단어들이 임베딩 공간에 제대로 표현되지 않는 문제
  - 원장이름, 병원이름 등의 단어들은 의미적 검색이 제대로 되지 않는 문제

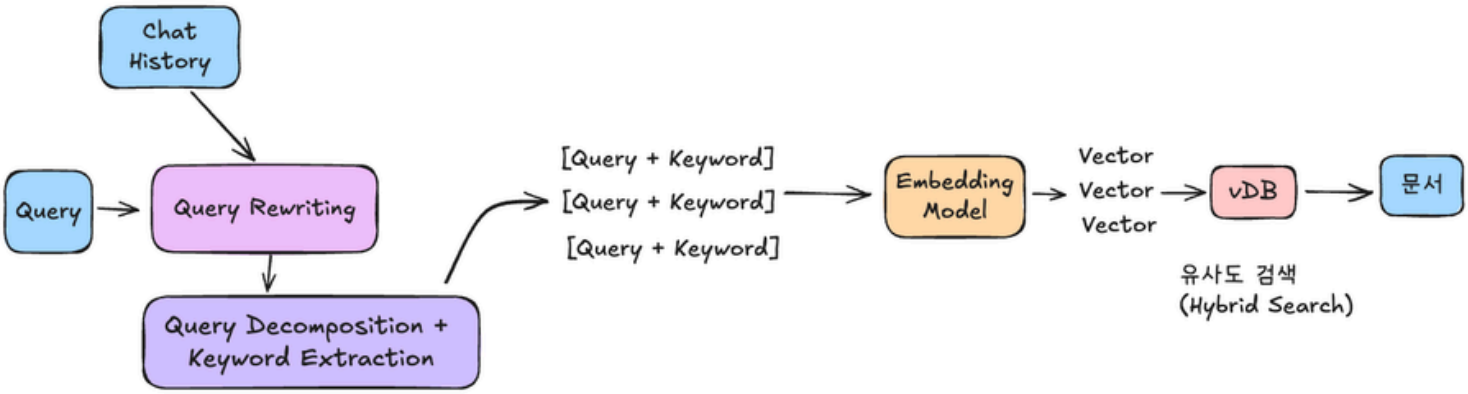

〈 해결 〉

- 대화기록을 반영해 질의를 재정의해 맥락을 반영한 문서 검색을 가능하게 구현
- 질문을 쪼개 복합질의를 단순 질의들로 분해하고, 각각에 대해 문서를 검색
- 질의에서 키워드를 추출해 도메인 특유의 단어들도 검색할 수 있게 구현

[Agentic-RAG 도입으로 검색 성능 및 관리 편의성 향상]

〈 문제 〉

- 서비스가 한국어·영어 중심 구조에서 일본어·중국어·베트남어를 포함한 다국어 환경으로 확장되면서, 기존 언어 특화 검색 모듈의 확장성 한계 발생
- 언어별로 분리된 문서와 인덱스를 개별 관리해야 하는 구조로 인해 운영 복잡도 및 관리 비용 증가
- 기존 검색 고도화 전략이 언어별 튜닝을 요구하며 유지보수 부담 확대

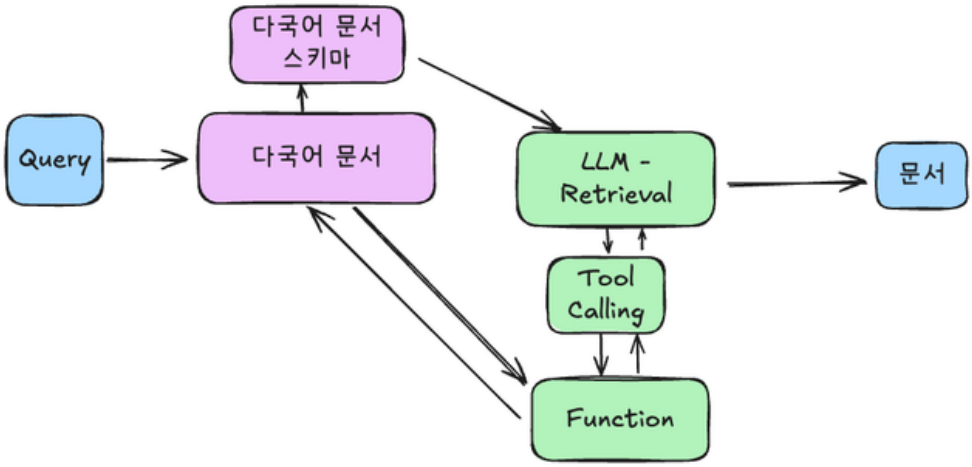

〈 해결 〉

- 대규모 context window를 저비용으로 처리 가능한 LLM의 등장에 따라, 벡터 인덱스 중심 구조를 재검토하고 검색 전략을 재설계
- 문서를 계층적·구조화된 형태(대주제-중주제-소주제)로 정리하고, 이를 기반으로 문서 스키마를 정의
- LLM이 문서 스키마를 이해하고 검색 tool을 동적으로 호출하도록 설계한 Agentic Retrieval 구조를 도입
- LLM이 단계적으로 필요한 문서를 탐색, 확장하며 충분한 근거를 확보한 뒤 응답을 생성하도록 구성

[LLM을 활용한 모니터링을 자동화해 유지보수 비용 감소]

〈 문제 〉

- Silent failure를 감지하기 위해 대화 로그를 검수해야 함
- 하루 200~300건 이상의 대화 로그를 사람이 검수하는 건 꽤나 큰 비용이 발생
- 모든 대화를 모두 확인해야 하는 방식은 비효율적

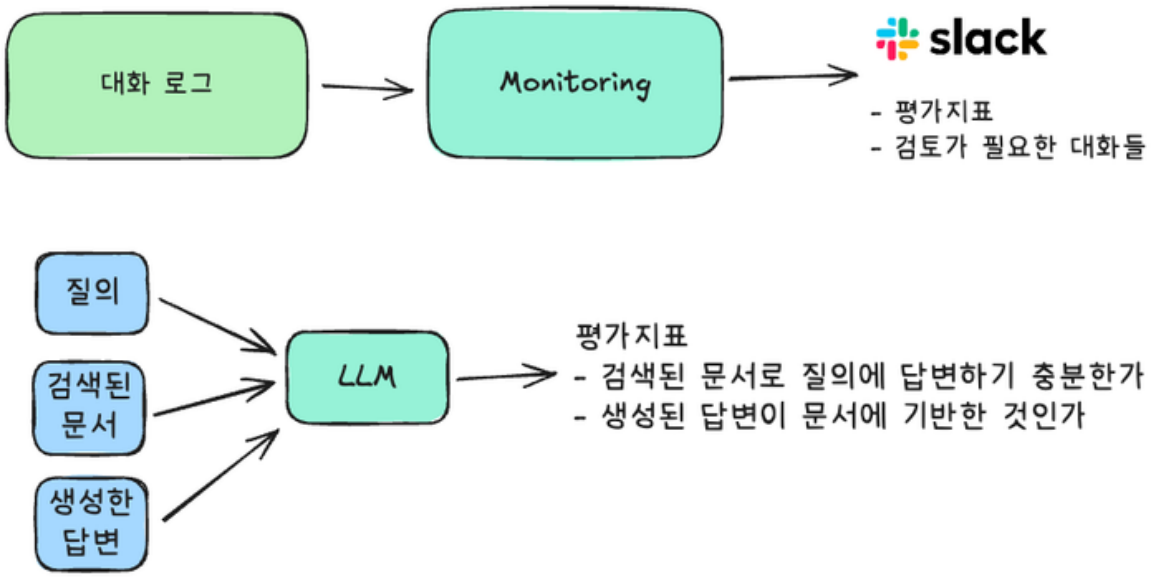

〈 해결 〉

- LLM을 활용해 대화 품질을 자동 평가하는 모니터링 파이프라인 설계
- RAG 구조를 평가할 수 있는 지표를 설계
  - 질의 + 문서 → 질의에 답변하기 충분한 문서인가
  - 문서 + 답변 → 답변이 문서에 기반했는가
- 각 대화에 대해 품질 점수를 자동으로 평가하고, 임계값 이하의 사례만 선별해 검수
- 평가 결과를 Slack으로 리포팅하도록 구현해 선택적으로 모니터링할 수 있는 환경 구성
- 이를 통해 유지보수 비용 감소

OCR 서비스 개발

[문제에 최적화된 OCR pipeline 개발]

〈 문제 〉

- 4~6종류의 장비에서 장비별 4~8장의 검사 결과 이미지가 생성
- 검사 결과가 이미지 형태로 파편화되어 있어 한눈에 검사 결과 확인이 어려움
- 수치 데이터가 정형화되지 않아 공식 계산 등에 활용 불가
- 사람이 수기로 데이터를 확인, 입력하는 과정에서 비효율 및 오류 가능성 존재
- 추후 AI 서비스 도입에 있어 주요한 병목 요소로 작용

〈 해결 〉

- OCR 파이프라인을 설계해 파편화된 이미지 데이터를 정규화된 구조의 데이터로 전환

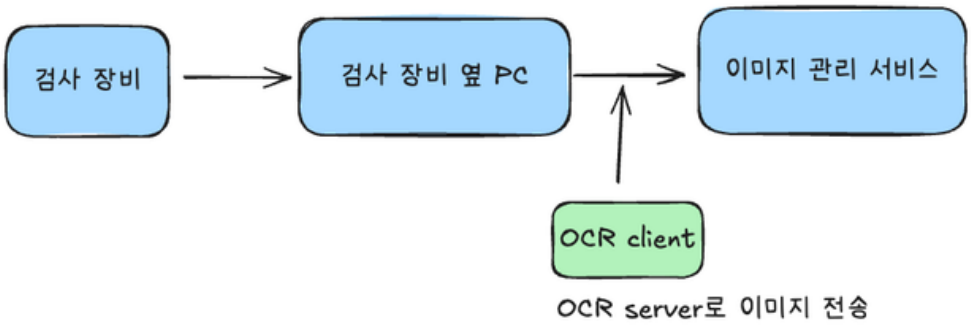

- 검사 이미지 생성·처리 흐름을 분석해 실무자의 추가 개입 없이 동작하도록 구조 설계

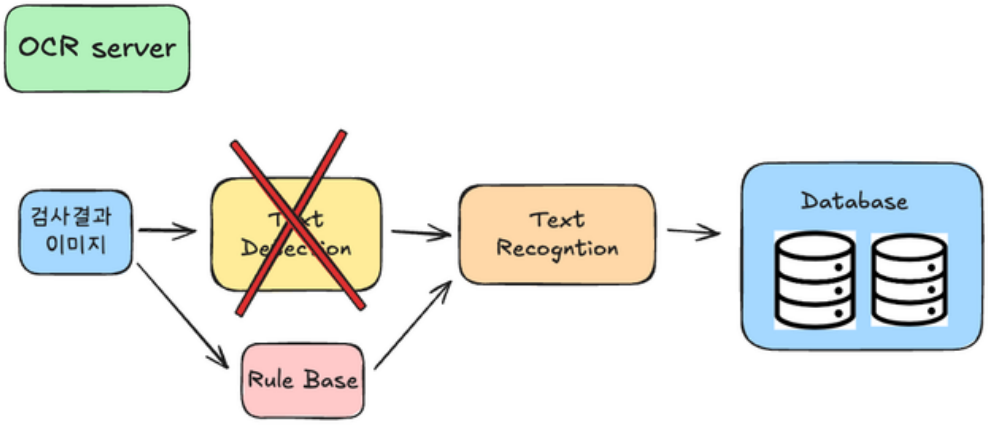

- 검사 이미지가 고정된 레이아웃이라는 특성을 활용해 Text Detection 모델 대신 Rule-based Detection 구조로 설계해 목표 정확도 및 처리속도 달성
- Text recognition에 특화된 모델 (TrOCR)을 도입하고 이미지 전처리 및 결과 후처리를 통해 정확도 99% 달성
- 객체지향 설계로 모듈화하고 Unit Test 기반 검증 체계를 적용해 런타임 오류를 줄이고 실서비스 환경에서 안정적으로 운영 가능한 파이프라인을 구축